Selección del Conjunto de Datos para el Proyecto Integrador

Proyecto Integrador METABRIC: Fase 1, Actividad 1

Martín Gracia Socha

Facultad de Ingeniería, Universidad de La Salle

Ciencia de Datos (2026-2): Maestría en Inteligencia Artificial

Fabián Camilo Castro Riveros

25 de octubre de 2026

Archivos ejecutables y recursos de esta entrega	
Repositorio del proyecto	https://github.com/MartinGia/metabric-proyecto-integrador
Datos originales	https://github.com/MartinGia/metabric-proyecto-integrador/tree/main/data/raw
Evidencia de la licencia	https://github.com/MartinGia/metabric-proyecto-integrador/tree/main/docs/evidencias
Cuaderno 01 (GitHub)	https://github.com/MartinGia/metabric-proyecto-integrador/blob/main/notebooks/01_EDA_Fase1.ipynb
Cuaderno 01 (Colab)	https://colab.research.google.com/github/MartinGia/metabric-proyecto-integrador/blob/main/notebooks/01_EDA_Fase1.ipynb

Modalidad de trabajo

El proyecto integrador se desarrollará de manera **individual**. El estudiante asume todas las fases del ciclo de vida del proyecto: planteamiento y EDA, preprocesamiento y modelo base, modelado avanzado y comunicación de resultados.

Conjunto de datos seleccionado

Tabla 1

Ficha técnica del conjunto de datos seleccionado

Campo	Detalle
Nombre	Breast Cancer Gene Expression Profiles (METABRIC)
Repositorio	Kaggle Datasets (repositorio permitido por la guía)
URL	https://www.kaggle.com/datasets/raghadalharbi/breast-cancer-gene-expression-profiles-metabric
Fuente primaria	cBioPortal for Cancer Genomics, estudio METABRIC (brca_metabric)
Licencia	Open Database License (ODbL) para la base de datos y Database Contents License (DbCL) v1.0 para los contenidos
Fecha de extracción	24 de octubre de 2026
Tamaño	1.904 registros (pacientes) × 693 variables; archivo CSV de 8,4 MB
Contenido	31 variables clínicas, z-scores de expresión de ARNm de 489 genes y estado mutacional de 173 genes

Justificación

Se eligió un conjunto de datos de **bioinformática médica**, en el área de la genómica del cáncer de mama. METABRIC (Molecular Taxonomy of Breast Cancer International Consortium) es una cohorte de referencia en oncología que integra información clínico-patológica con perfiles de expresión génica y mutaciones del tumor primario (Curtis et al., 2012; Pereira et al., 2016). Su elección se apoya en tres razones:

- **Relevancia del problema:** el cáncer de mama es molecularmente heterogéneo, y estimar el pronóstico y el subtipo molecular de cada paciente es una necesidad clínica real.
- **Versatilidad analítica:** el mismo conjunto permite plantear de forma natural los tres problemas que exige la guía (regresión, clasificación y clustering).

- **Riqueza para el EDA:** combina tipos de variables, presenta datos faltantes reales, valores atípicos e incoherencias que justifican un preprocesamiento riguroso.

Verificación de los requisitos de la guía

Tabla 2

Verificación de los requisitos de la guía

Requisito	METABRIC	Cumple
Repositorio público con licencia libre	Kaggle, ODbL/DbCL	Sí
No es un dataset didáctico	Datos reales de un consorcio de investigación (Curtis et al., 2012)	Sí
Mínimo 600 registros	1.904	Sí
Mínimo 5 variables de distintos tipos	693: cuantitativas continuas y discretas, cualitativas nominales y ordinales	Sí
Variable continua para regresión	nottingham_prognostic_index	Sí
Variable categórica para clasificación	pam50_+_claudin-low_subtype (6 clases)	Sí
Varias cuantitativas para clustering	489 z-scores de expresión génica	Sí

Variables objetivo propuestas

Tabla 3

Variables objetivo propuestas

Tarea	Variable	Tipo	Justificación
Regresión	nottingham_prognostic_index (NPI)	Cuantitativa continua	Índice pronóstico clínico (Haybittle et al., 1982). Se estimará sin usar sus componentes (tamaño tumoral, ganglios positivos y grado) para evitar fuga de información.
Clasificación	pam50_+_claudin-low_subtype	Cualitativa nominal	Subtipo molecular intrínseco (Parker et al., 2009) con implicaciones terapéuticas directas.
Clustering	Expresión de 489 genes	Cuantitativas continuas	Permite descubrir grupos de pacientes y contrastarlos con los subtipos PAM50 conocidos.

Siguiente paso

Con el conjunto de datos definido, el Entregable 1 (actividad 2, 1 de noviembre de 2026) presentará el planteamiento del problema, los objetivos SMART, la ficha técnica con el

diccionario de datos y el análisis exploratorio completo. El código se organiza en un repositorio con la estructura /data, /notebooks, /src y /dashboard.

Referencias

Alharbi, R. (2020). *Breast cancer gene expression profiles (METABRIC)* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/raghadalharbi/breast-cancer-gene-expression-profiles-metabric

Cerami, E., Gao, J., Dogrusoz, U., Gross, B. E., Sumer, S. O., Aksoy, B. A., Jacobsen, A., Byrne, C. J., Heuer, M. L., Larsson, E., Antipin, Y., Reva, B., Goldberg, A. P., Sander, C. y Schultz, N. (2012). The cBio cancer genomics portal: An open platform for exploring multidimensional cancer genomics data. *Cancer Discovery, 2*(5), 401–404. https://doi.org/10.1158/2159-8290.CD-12-0095

Curtis, C., Shah, S. P., Chin, S.-F., Turashvili, G., Rueda, O. M., Dunning, M. J., Speed, D., Lynch, A. G., Samarajiwa, S., Yuan, Y., Gräf, S., Ha, G., Haffari, G., Bashashati, A., Russell, R., McKinney, S., METABRIC Group, Langerød, A., Green, A., … Aparicio, S. (2012). The genomic and transcriptomic architecture of 2,000 breast tumours reveals novel subgroups. *Nature, 486*(7403), 346–352. https://doi.org/10.1038/nature10983

Haybittle, J. L., Blamey, R. W., Elston, C. W., Johnson, J., Doyle, P. J., Campbell, F. C., Nicholson, R. I. y Griffiths, K. (1982). A prognostic index in primary breast cancer. *British Journal of Cancer, 45*(3), 361–366. https://doi.org/10.1038/bjc.1982.62

Parker, J. S., Mullins, M., Cheang, M. C. U., Leung, S., Voduc, D., Vickery, T., Davies, S., Fauron, C., He, X., Hu, Z., Quackenbush, J. F., Stijleman, I. J., Palazzo, J., Marron, J. S., Nobel, A. B., Mardis, E., Nielsen, T. O., Ellis, M. J., Perou, C. M. y Bernard, P. S. (2009). Supervised risk predictor of breast cancer based on intrinsic subtypes. *Journal of Clinical Oncology, 27*(8), 1160–1167. https://doi.org/10.1200/JCO.2008.18.8370

Pereira, B., Chin, S.-F., Rueda, O. M., Vollan, H.-K. M., Provenzano, E., Bardwell, H. A., Pugh, M., Jones, L., Russell, R., Sammut, S.-J., Tsui, D. W. Y., Liu, B., Dawson, S.-J., Abraham, J., Northen, H., Peden, J. F., Mukherjee, A., Turashvili, G., Green, A. R., … Caldas, C. (2016). The somatic mutation profiles of 2,433 breast cancers refine their

genomic and transcriptomic landscapes. *Nature Communications, 7*, Artículo 11479. https://doi.org/10.1038/ncomms11479