Limpieza de Datos e Ingeniería de Variables

Proyecto Integrador METABRIC: Fase 2, Actividad 3

Martín Gracia Socha

Facultad de Ingeniería, Universidad de La Salle

Ciencia de Datos (2026-2): Maestría en Inteligencia Artificial

Fabián Camilo Castro Riveros

8 de noviembre de 2026

Archivos ejecutables y recursos de esta entrega	
Repositorio del proyecto	https://github.com/MartinGia/metabric-proyecto-integrador
Cuaderno 02 (GitHub)	https://github.com/MartinGia/metabric-proyecto-integrador/blob/main/notebooks/02_Limpieza_Ingenieria_Variables.ipynb
Cuaderno 02 (Colab)	https://colab.research.google.com/github/MartinGia/metabric-proyecto-integrador/blob/main/notebooks/02_Limpieza_Ingenieria_Variables.ipynb
Módulo de limpieza	https://github.com/MartinGia/metabric-proyecto-integrador/blob/main/src/cleaning.py
Variables derivadas	https://github.com/MartinGia/metabric-proyecto-integrador/blob/main/src/features.py
Pipeline sin fuga	https://github.com/MartinGia/metabric-proyecto-integrador/blob/main/src/preprocessing.py
Datos procesados	https://github.com/MartinGia/metabric-proyecto-integrador/tree/main/data/processed

Los cuadernos se pueden abrir y ejecutar directamente en Google Colab: la primera celda clona el repositorio e instala las dependencias que falten.

Limpieza de Datos e Ingeniería de Variables

Esta actividad prepara los datos de METABRIC (Curtis et al., 2012; Pereira et al., 2016) para el modelado. El principio rector es evitar la **fuga de información**: las transformaciones determinísticas, que no aprenden parámetros de los datos, se aplican antes de la partición; las que sí aprenden (percentiles, imputadores, escalado y codificación) se ajustan solo con el conjunto de entrenamiento dentro de un `Pipeline` de scikit-learn (Pedregosa et al., 2011). Por esa razón, la partición 70/15/15 estratificada por subtipo se fijó en esta actividad y se reutiliza en todas las siguientes.

Limpieza Determinística

La Tabla 1 resume las 12 reglas aplicadas. Tras excluir el único sarcoma, la cohorte queda en 1.903 pacientes. Dos hallazgos merecen destacarse. Primero, la fórmula del Nottingham Prognostic Index (Haybittle et al., 1982), tal como aparece en la fuente, reproduce el grado observado en el 99,8 % de los registros completos; esto permitió deducir 18 grados faltantes sin estimar nada. Segundo, en 57 registros el NPI se calculó sin el grado o es incoherente con sus componentes (media de 1,9 frente a 4,1), por lo que se marcaron como no válidos y se excluyen del problema de regresión.

Tabla 1

Reglas de limpieza determinística aplicadas

Acción	Registros	Justificación
Corregir ’Positve’ por ’Positive’	1.445	Error tipográfico en la fuente.
Excluir el sarcoma de mama	1	No es un carcinoma; caso único fuera de la población.
HER2 por SNP6 ’UNDEF’ a faltante	4	Es un valor indeterminado, no una categoría.
Estadio 0 a faltante	4	Estadio in situ incoherente con carcinomas invasivos de 11 a 65 mm.
mutation_count faltante a 0	45	MNAR estructural: el mínimo observado es 1 y todos los faltantes tienen 0 mutaciones en el panel.
Deducir el grado desde el NPI	18	NPI = grado + estadio ganglionar + 0,002 x tamaño; el grado se despeja sin estimar nada.
Marcar NPI no válido (npi_valid = 0)	57	El NPI se calculó sin el grado (residuo 0) o no es coherente con sus componentes.
Codificar cellularity como ordinal (1 a 3)	1.849	Orden natural Low < Moderate < High; mapeo fijo, sin aprendizaje.

Acción	Registros	Justificación
Mutaciones a indicadores 0/1	1.903	173 columnas; el cambio de proteína no se usa en los modelos.
Eliminar oncotree_code	0	Redundante: mapeo uno a uno con cancer_type_detailed.
Eliminar cancer_type	0	Constante tras excluir el único sarcoma.
Eliminar er_status_measured_by_ihc	0	Redundante con er_status (completa); 118 discrepancias entre métodos.

Nota. Ninguna regla usa estadísticos del conjunto de datos; por eso pueden aplicarse antes de la partición.

Mecanismo de los Datos Faltantes

Antes de imputar, se analizó el mecanismo de falta de cada variable (Little y Rubin, 2019). El indicador de ausencia se comparó con la cohorte, el subtipo, los receptores, la edad, el NPI y la supervivencia mediante pruebas χ^2 y U de Mann-Whitney con corrección de Bonferroni (77 pruebas; $\alpha = 6{,}5 \times 10^{-4}$). Si alguna asociación resultaba significativa, se descartó MCAR. La Tabla 2 muestra el resultado: siete variables son MAR, la mayoría por diferencias entre los centros de reclutamiento; dos son compatibles con MCAR y `mutation_count` es MNAR estructural.

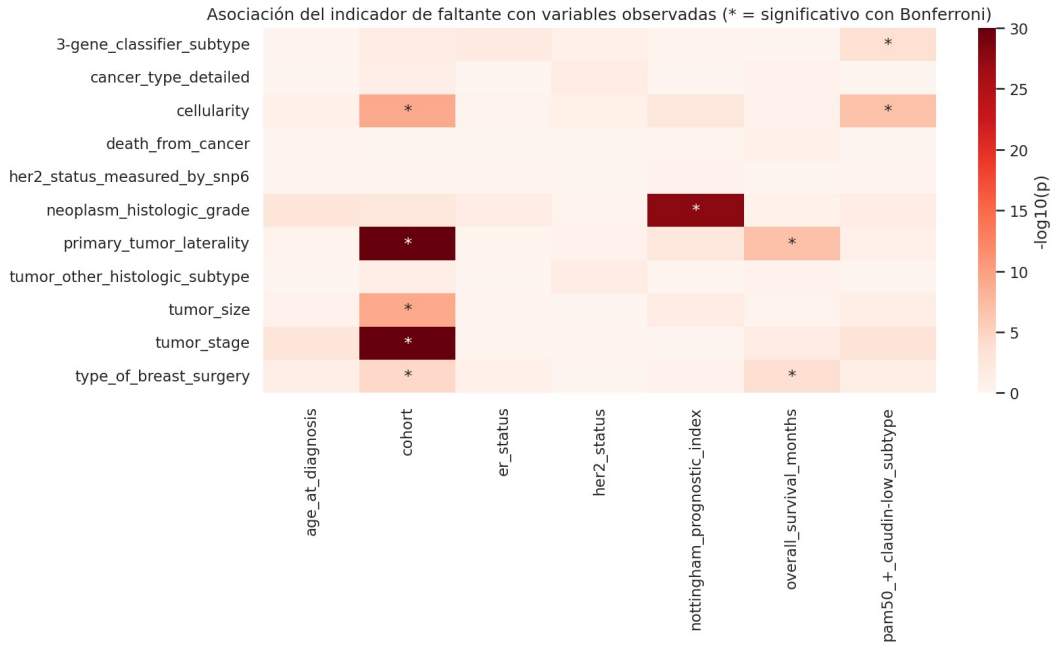
Tabla 2

Mecanismo de falta y tratamiento por variable

Variable	% faltante	Mecanismo	Asociación significativa	Tratamiento
tumor_stage	26,5	MAR	Cohorte (100 % en C4; 84 % en C5)	Excluida de los predictores; versión descriptiva por regla TNM
3-gene_classifier_subtype	10,7	MAR	Subtipo PAM50	Excluida (etiqueta derivada de la expresión génica)
primary_tumor_laterality	5,5	MAR	Cohorte y supervivencia	Excluida (sin relación biológica con los objetivos)
cellularity	2,8	MAR	Cohorte y subtipo PAM50	IterativeImputer ajustado en entrenamiento
neoplasm_histologic_grade	2,8	MAR	NPI	Deducción exacta desde el NPI (18) e IterativeImputer
type_of_breast_surgery	1,1	MAR	Cohorte y supervivencia	Excluida (tratamiento posterior al diagnóstico)
tumor_size	1,0	MAR	Cohorte (C5)	IterativeImputer sobre su logaritmo
tumor_other_histologic_subtype	0,8	MCAR	Ninguna significativa	Categoría «Desconocido» antes del One-Hot
her2_status_measured_by_snp6	0,2	MCAR	Ninguna significativa	Categoría «Desconocido»
mutation_count	2,4	MNAR	Falta cuando el valor es 0	Imputación determinística con 0

Figura 1

Asociación del indicador de faltante con variables observadas



Nota. Las celdas marcadas con asterisco son significativas tras la corrección de Bonferroni.

Tratamiento de Valores Atípicos

Los valores atípicos del tamaño tumoral, los ganglios positivos y el número de mutaciones son clínicamente plausibles, así que no se eliminaron. Se aplicó una transformación `log1p` seguida de winsorización en los percentiles 1 y 99, aprendidos solo en entrenamiento. La asimetría del tamaño tumoral bajó de 3,3 a 0,1 y la del número de mutaciones de 4,9 a −0,6. Los z-scores de expresión génica no se recortaron, porque sus extremos pueden reflejar amplificaciones o pérdidas con significado biológico.

Variables Derivadas

Se crearon 11 variables a partir del conocimiento del dominio (Tabla 3). Todas se calculan fila por fila con reglas o listas de genes tomadas de la literatura, por lo que no introducen fuga. El puntaje de proliferación se correlaciona con el grado histológico (ρ = 0,54) y

con el NPI válido (ρ = 0,40). El grupo por receptores es coherente con la biología: el 96,6 % de los tumores Luminal A son HR+/HER2− y el 75,9 % de los Basal son triple negativos (Figura 2).

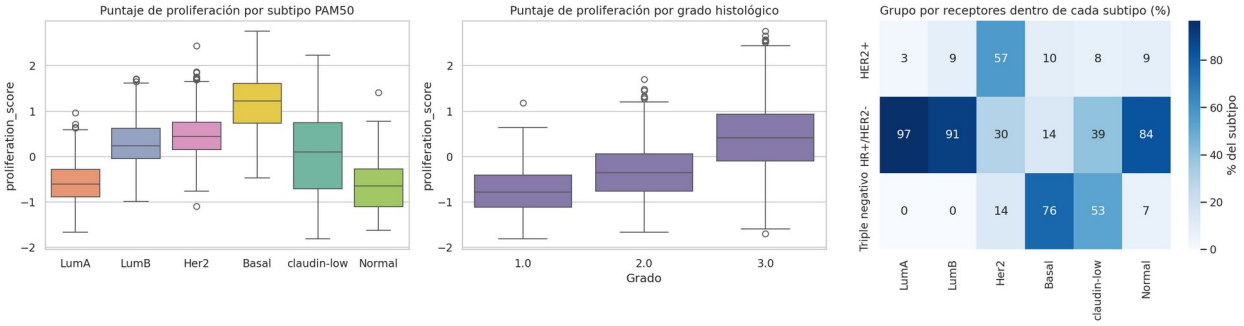
Tabla 3

Variables derivadas y su justificación

Variable	Definición	Respaldo
proliferation_score	Promedio de los z-scores de AURKA, CCNB1, CDK1, CHEK1, CCNE1, CDC25A y E2F2	Paik et al. (2004); Sotiriou et al. (2006)
receptor_group	HR+/HER2−, HER2+ o triple negativo según ER, PR y HER2	Goldhirsch et al. (2011)
triple_negative	1 si ER−, PR− y HER2−	Goldhirsch et al. (2011)
driver_mutation_count	Número de genes conductores mutados (15 genes)	Pereira et al. (2016)
log_* (3 variables)	log1p del tamaño tumoral, los ganglios positivos y el número de mutaciones	Reducción de asimetría
node_category, age_group	Categorías N0 / N1-3 / N4+ y grupos de edad	Perfiles y filtros del dashboard
tumor_stage_rule	Estadio anatómico por regla TNM (tamaño y ganglios)	Solo descriptiva

Figura 2

Validación de las variables derivadas frente a variables conocidas



Selección del Método de Imputación

Para elegir el imputador con evidencia, se ocultó al azar el 15 % de los valores observados del grado y la celularidad dentro de entrenamiento, se imputaron con cada método y se midió la exactitud tras redondear al nivel ordinal más cercano (20 repeticiones). IterativeImputer, basado en ecuaciones encadenadas (van Buuren y Groothuis-Oudshoorn, 2011), recuperó el grado con una exactitud de 0,978, frente a 0,871 de KNNImputer y 0,500 de la moda

(Tabla 4). Para la celularidad todos los métodos rondan 0,49, lo que indica que la variable aporta poca información; se mantuvo IterativeImputer por su menor error absoluto.

Tabla 4

Exactitud de la imputación en valores enmascarados (entrenamiento)

Variable	Método	Exactitud	MAE
Grado histológico	IterativeImputer	0,978	0,168
	KNNImputer (k = 5)	0,871	0,180
	Moda / mediana	0,500	0,592
Celularidad	IterativeImputer	0,490	0,566
	KNNImputer (k = 5)	0,483	0,577
	Moda	0,497	0,609

Nota. Promedio de 20 repeticiones con el 15 % de los valores observados ocultos.

Pipeline de Preprocesamiento y Partición

El `ColumnTransformer` final aplica a las variables clínicas winsorización, escalado estándar e IterativeImputer; a las nominales, imputación con la categoría «Desconocido» y codificación One-Hot; a los 489 genes, escalado estándar; y deja sin cambios las 71 variables binarias. Se ajusta solo con entrenamiento: las medias de los genes son 0 en entrenamiento y distintas de 0 en validación (0,001) y prueba (0,008), señal de que sus estadísticos no se usaron. La partición estratificada deja 1.332, 285 y 286 pacientes, con la misma distribución de subtipos en los tres subconjuntos (χ^2, p = 1,00).

Conclusiones

Los datos quedan limpios, documentados y listos para modelar. Cada imputación tiene un mecanismo de falta justificado, los atípicos se tratan sin perder pacientes, las variables derivadas tienen respaldo bibliográfico y todo el preprocesamiento aprendido está encapsulado para evitar la fuga de información. Los artefactos generados (`metabric_clean.csv`, `splits.csv` y `feature_sets.json`) son la base de las actividades 4 a 7.

Referencias

Curtis, C., Shah, S. P., Chin, S.-F., Turashvili, G., Rueda, O. M., Dunning, M. J., Speed, D., Lynch, A. G., Samarajiwa, S., Yuan, Y., Gräf, S., Ha, G., Haffari, G., Bashashati, A., Russell, R., McKinney, S., METABRIC Group, Langerød, A., Green, A., … Aparicio, S. (2012). The genomic and transcriptomic architecture of 2,000 breast tumours reveals novel subgroups. *Nature*, *486*(7403), 346–352. https://doi.org/10.1038/nature10983

Goldhirsch, A., Wood, W. C., Coates, A. S., Gelber, R. D., Thürlimann, B., Senn, H.-J. y Panel members. (2011). Strategies for subtypes—Dealing with the diversity of breast cancer: Highlights of the St Gallen International Expert Consensus on the Primary Therapy of Early Breast Cancer 2011. *Annals of Oncology*, *22*(8), 1736–1747. https://doi.org/10.1093/annonc/mdr304

Haybittle, J. L., Blamey, R. W., Elston, C. W., Johnson, J., Doyle, P. J., Campbell, F. C., Nicholson, R. I. y Griffiths, K. (1982). A prognostic index in primary breast cancer. *British Journal of Cancer*, *45*(3), 361–366. https://doi.org/10.1038/bjc.1982.62

Little, R. J. A. y Rubin, D. B. (2019). *Statistical analysis with missing data* (3.ª ed.). Wiley. https://doi.org/10.1002/9781119482260

Paik, S., Shak, S., Tang, G., Kim, C., Baker, J., Cronin, M., Baehner, F. L., Walker, M. G., Watson, D., Park, T., Hiller, W., Fisher, E. R., Wickerham, D. L., Bryant, J. y Wolmark, N. (2004). A multigene assay to predict recurrence of tamoxifen-treated, node-negative breast cancer. *The New England Journal of Medicine*, *351*(27), 2817–2826. https://doi.org/10.1056/NEJMoa041588

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M. y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825–2830. https://jmlr.org/papers/v12/pedregosa11a.html

Pereira, B., Chin, S.-F., Rueda, O. M., Vollan, H.-K. M., Provenzano, E., Bardwell, H. A., Pugh, M., Jones, L., Russell, R., Sammut, S.-J., Tsui, D. W. Y., Liu, B., Dawson, S.-J., Abraham, J., Northen, H., Peden, J. F., Mukherjee, A., Turashvili, G., Green, A. R., … Caldas, C. (2016). The somatic mutation profiles of 2,433 breast cancers refine their genomic and transcriptomic landscapes. *Nature Communications, 7*, Artículo 11479. https://doi.org/10.1038/ncomms11479

Sotiriou, C., Wirapati, P., Loi, S., Harris, A., Fox, S., Smeds, J., Nordgren, H., Farmer, P., Praz, V., Haibe-Kains, B., Desmedt, C., Larsimont, D., Cardoso, F., Peterse, H., Nuyten, D., Buyse, M., Van de Vijver, M. J., Bergh, J., Piccart, M. y Delorenzi, M. (2006). Gene expression profiling in breast cancer: Understanding the molecular basis of histologic grade to improve prognosis. *Journal of the National Cancer Institute, 98*(4), 262–272. https://doi.org/10.1093/jnci/djj052

van Buuren, S. y Groothuis-Oudshoorn, K. (2011). mice: Multivariate imputation by chained equations in R. *Journal of Statistical Software*, *45*(3), 1–67. https://doi.org/10.18637/jss.v045.i03