Predicción del Pronóstico y del Subtipo Molecular del Cáncer de Mama con Datos Clínicos y Genómicos de METABRIC

Informe técnico final del Proyecto Integrador (Fase 4, Actividad 8)

Martín Gracia Socha

Facultad de Ingeniería, Universidad de La Salle

Ciencia de Datos (2026-2): Maestría en Inteligencia Artificial

Fabián Camilo Castro Riveros

28 de noviembre de 2026

Archivos ejecutables y recursos de esta entrega	
Repositorio del proyecto	https://github.com/MartinGia/metabric-proyecto-integrador
Dashboard en línea	https://metabric-proyecto-integrador.streamlit.app
Cuadernos (carpeta)	https://github.com/MartinGia/metabric-proyecto-integrador/tree/main/notebooks
Cuaderno 01 en Colab	https://colab.research.google.com/github/MartinGia/metabric-proyecto-integrador/blob/main/notebooks/01_EDA_Fase1.ipynb
Cuaderno 06 en Colab	https://colab.research.google.com/github/MartinGia/metabric-proyecto-integrador/blob/main/notebooks/06_Evaluacion_Interpretabilidad.ipynb

Todo el análisis se puede reproducir clonando el repositorio, instalando requirements.txt y ejecutando los cuadernos 01 a 06 en orden.

Resumen

El cáncer de mama es una enfermedad heterogénea cuyo pronóstico y tratamiento dependen de factores clínicos y moleculares. Este trabajo aplica el ciclo completo de la ciencia de datos al conjunto METABRIC (1.904 pacientes; 693 variables clínicas, de expresión génica y de mutaciones) con tres objetivos: estimar el Nottingham Prognostic Index (NPI) sin usar sus componentes, clasificar el subtipo molecular PAM50 y segmentar a las pacientes en perfiles de riesgo. Se aplicó una limpieza determinística con análisis del mecanismo de los datos faltantes, ingeniería de variables con respaldo bibliográfico y un preprocesamiento encapsulado en *pipelines* para evitar la fuga de información. Con una partición estratificada 70/15/15 y validación cruzada de 5 pliegues se compararon modelos lineales regularizados, ensambles de árboles, máquinas de vectores de soporte y un perceptrón multicapa. En el conjunto de prueba, la regresión Ridge alcanzó $R^2 = 0{,}260$ (IC 95 %: 0,175 a 0,332); el clasificador final, que combina la selección de 200 genes con una regresión logística regularizada, obtuvo F1 macro = 0,792 (IC 95 %: 0,735 a 0,843) y AUC-ROC = 0,967 con una brecha de sobreajuste de 0,123; y K-Means identificó cuatro perfiles, uno de ellos atribuible a un efecto de lote. El análisis SHAP mostró que los modelos redescubren la biología conocida de los subtipos. Los resultados se comunican en un dashboard interactivo.

Palabras clave: cáncer de mama, METABRIC, aprendizaje automático, subtipos PAM50, interpretabilidad

Abstract

Breast cancer is a heterogeneous disease whose prognosis and treatment depend on clinical and molecular factors. This work applies the full data science cycle to the METABRIC dataset (1,904 patients; 693 clinical, gene expression and mutation variables) with three goals: to estimate the Nottingham Prognostic Index (NPI) without using its components, to classify the PAM50 molecular subtype, and to segment patients into risk profiles. Deterministic cleaning with a missing-data mechanism analysis, literature-based feature engineering, and preprocessing encapsulated in pipelines were applied to prevent data leakage. Using a stratified 70/15/15 split and 5-fold cross-validation, regularized linear models, tree ensembles, support vector machines and a multilayer perceptron were compared. On the test set, Ridge regression reached $R^2 = 0.260$ (95% CI: 0.175 to 0.332); the final classifier, which combines the selection of 200 genes with regularized logistic regression, achieved a macro F1 = 0.792 (95% CI: 0.735 to 0.843) and an AUC-ROC = 0.967 with an overfitting gap of 0.123; and K-Means identified four profiles, one of them attributable to a batch effect. SHAP analysis showed that the models rediscover the known biology of the subtypes. The results are communicated through an interactive dashboard.

Keywords: breast cancer, METABRIC, machine learning, PAM50 subtypes, interpretability

Predicción del Pronóstico y del Subtipo Molecular del Cáncer de Mama

Introducción

El cáncer de mama es el cáncer más diagnosticado en el mundo, con cerca de 2,3 millones de casos nuevos en 2020 (Sung et al., 2021). No es una sola enfermedad: los tumores difieren en sus receptores hormonales, su capacidad de proliferar y su respuesta al tratamiento. La clasificación molecular intrínseca, basada en la expresión de 50 genes (PAM50), distingue los subtipos Luminal A, Luminal B, HER2-enriquecido, Basal y Normal-like, con pronósticos distintos (Parker et al., 2009); a ellos se suma el subtipo claudin-low (Prat et al., 2010). En la práctica clínica, el pronóstico se resume con índices como el Nottingham Prognostic Index (NPI), que combina el tamaño del tumor, el número de ganglios afectados y el grado histológico (Haybittle et al., 1982).

El estudio METABRIC (*Molecular Taxonomy of Breast Cancer International Consortium*) perfiló la expresión génica, el número de copias y las mutaciones de cerca de 2.000 tumores con seguimiento clínico a largo plazo (Curtis et al., 2012; Pereira et al., 2016). Su combinación de datos clínicos y genómicos lo convierte en un caso de estudio adecuado para el ciclo completo de la ciencia de datos.

Este proyecto plantea tres preguntas. Primera: ¿cuánto del pronóstico clínico, medido por el NPI, puede anticiparse a partir de la biología del tumor, sin usar las variables con las que se calcula? Segunda: ¿puede la expresión génica identificar el subtipo PAM50 de forma confiable y mejor que los receptores clínicos? Tercera: ¿se agrupan las pacientes de forma natural en perfiles con pronóstico distinto? Para cada pregunta se fijaron objetivos SMART medibles en un conjunto de prueba reservado: $R^2 \geq 0{,}20$ en la regresión, F1 macro $\geq 0{,}75$ con una brecha de sobreajuste menor que 0,15 en la clasificación, y una segmentación justificada con al menos dos algoritmos y perfiles interpretables.

Metodología

Datos

Se usó la versión de METABRIC publicada en Kaggle (Alharbi, 2020), derivada de cBioPortal (Cerami et al., 2012). Contiene 1.904 pacientes y 693 variables (Tabla 1). Tras excluir un sarcoma, el análisis se hizo sobre 1.903 pacientes.

Tabla 1

Bloques de variables del conjunto METABRIC

Bloque	Variables	Contenido
Clínicas	31	Edad, tamaño tumoral, ganglios, grado, receptores, cohorte, tratamientos y supervivencia
Expresión génica	489	Z-scores de ARNm (Illumina HT-12 v3) de genes asociados al cáncer
Mutaciones	173	Mutación somática por gen (secuenciación dirigida)

Análisis Exploratorio

El análisis exploratorio cubrió estadística descriptiva, distribuciones, valores faltantes, atípicos por los criterios IQR y z-score, correlaciones de Pearson y Spearman, asociaciones con V de Cramér corregida (Bergsma, 2013) y pruebas χ^2. Se usaron pandas (McKinney, 2010), NumPy (Harris et al., 2020), SciPy (Virtanen et al., 2020), Matplotlib (Hunter, 2007) y seaborn (Waskom, 2021).

Limpieza y Prevención de la Fuga de Información

La limpieza se dividió en dos tipos de operaciones. Las determinísticas, que no aprenden de los datos, se aplicaron antes de la partición: unificación de categorías, deducción exacta de 18 grados faltantes a partir de la fórmula del NPI y marcado de 57 NPI no válidos. Las que aprenden parámetros se encapsularon en un `Pipeline` de scikit-learn (Pedregosa et al., 2011) que se ajusta solo con entrenamiento: winsorización en los percentiles 1 y 99, escalado estándar, imputación con IterativeImputer (van Buuren y Groothuis-Oudshoorn, 2011) y codificación One-Hot. El mecanismo de cada faltante (MCAR, MAR o MNAR) se determinó con pruebas de asociación corregidas por Bonferroni (Little y Rubin, 2019), y el imputador se eligió con un

experimento de enmascaramiento: IterativeImputer recuperó el grado histológico con una exactitud de 0,978.

Se crearon 11 variables derivadas, entre ellas un puntaje de proliferación basado en siete genes (Paik et al., 2004; Sotiriou et al., 2006), el grupo por receptores y el indicador de triple negativo (Goldhirsch et al., 2011), y el número de mutaciones en genes conductores (Pereira et al., 2016). Para la regresión se excluyeron el tamaño tumoral, los ganglios y el grado, porque el NPI se calcula con ellos.

Partición y Protocolo de Evaluación

Los datos se dividieron en entrenamiento (1.332), validación (285) y prueba (286), con estratificación por subtipo y semilla fija. Los hiperparámetros se eligieron con validación cruzada de 5 pliegues en entrenamiento; la validación se usó para comparar modelos ajustados; y la prueba se usó una sola vez, al final. Antes de abrir la prueba se fijaron las reglas de selección: la regla de un error estándar para la regresión (Hastie et al., 2009) y, para la clasificación, el mayor F1 macro de CV entre las configuraciones con brecha menor que 0,15. El desbalance de clases (razón 4,85) se trató con ponderación por clase, tras compararla con SMOTE (Chawla et al., 2002; Lemaître et al., 2017).

Modelos

Como referencia se usaron una regresión lineal simple con el puntaje de proliferación y una regresión logística sin ajustar. En regresión se compararon Ridge, ElasticNet, Random Forest y XGBoost (Chen y Guestrin, 2016). En clasificación se compararon una regresión logística L2, una SVM con kernel RBF, Random Forest, XGBoost y un perceptrón multicapa en PyTorch (Paszke et al., 2019) con dos capas ocultas, *dropout* y parada temprana. Para reducir el sobreajuste se evaluó la selección de variables con la prueba F de ANOVA dentro del *pipeline*. La segmentación se hizo sobre las 10 primeras componentes principales de la expresión génica con K-Means, eligiendo K con el método del codo (Satopää et al., 2011) y el coeficiente de silueta (Rousseeuw, 1987); se contrastó con el clustering jerárquico de Ward (1963) y con DBSCAN (Ester et al., 1996).

Evaluación e Interpretabilidad

Las métricas en prueba se acompañan de intervalos de confianza del 95 % por *bootstrap* (Efron y Tibshirani, 1993). Los modelos se compararon con la prueba de Wilcoxon sobre los errores absolutos en regresión y con la prueba de McNemar (1947) en clasificación. La interpretabilidad se basó en coeficientes estandarizados, importancia por permutación y valores SHAP (Lundberg y Lee, 2017; Lundberg et al., 2020). La estabilidad de los clústeres se midió con el índice de Rand ajustado (ARI; Hubert y Arabie, 1985).

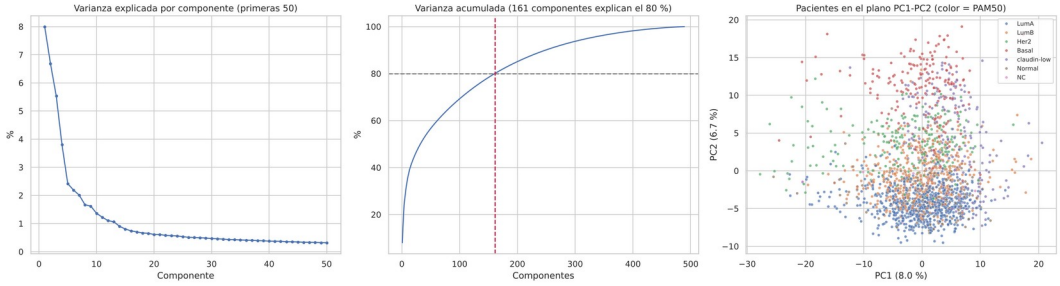
Resultados

Hallazgos del Análisis Exploratorio

La cohorte tiene una edad media al diagnóstico de 61 años; el 76 % de los tumores son ER positivos y Luminal A es el subtipo más frecuente (36 %). El NPI se asocia con el subtipo: es mayor en los tumores Basal y HER2 y menor en Luminal A. Los genes de proliferación se correlacionan positivamente con el NPI, y la proyección de la expresión génica en componentes principales separa con claridad los tumores ER negativos (Figura 1). La variable con más faltantes es el estadio tumoral (26,5 %), cuya ausencia depende del centro de reclutamiento.

Figura 1

Proyección de la expresión génica en las dos primeras componentes principales, coloreada por subtipo PAM50



Regresión del NPI

En el conjunto de prueba, Ridge alcanzó $R^2 = 0{,}260$ y RMSE = 0,902, frente a 0,949 del modelo base (Tabla 2). La mejora frente al modelo base es significativa en RMSE (diferencia de

0,047; IC 95 %: 0,004 a 0,088). Los cuatro modelos avanzados son estadísticamente equivalentes entre sí (p > 0,2 en la prueba de Wilcoxon), lo que respalda elegir el más simple.

Tabla 2

Regresión del NPI en el conjunto de prueba

Modelo	R^2	IC 95 % R^2	RMSE	IC 95 % RMSE	MAE
Dummy (media)	-0,000	[-0,019; -0,000]	1,048	[0,964; 1,123]	0,792
Base: lineal simple (proliferación)	0,181	[0,094; 0,254]	0,949	[0,871; 1,025]	0,754
Ridge	0,260	[0,175; 0,332]	0,902	[0,838; 0,969]	0,730
ElasticNet / Lasso	0,248	[0,163; 0,320]	0,909	[0,841; 0,981]	0,732
Random Forest	0,257	[0,175; 0,327]	0,904	[0,832; 0,977]	0,729
XGBoost	0,261	[0,162; 0,339]	0,901	[0,832; 0,975]	0,715

Nota. IC 95 % por bootstrap con 1.000 remuestreos del conjunto de prueba (n = 281 con NPI válido).

Clasificación del Subtipo PAM50

Los modelos con expresión génica superan con amplitud a una logística que solo usa ER, PR y HER2 (F1 macro de 0,38 en validación). Los modelos de la fase de ajuste presentaban brechas de sobreajuste de 0,22 a 0,27; la selección de 200 genes con una logística muy regularizada (C = 0,01) la redujo a 0,123 manteniendo un F1 de CV de 0,739. En prueba, este clasificador final obtuvo el mejor desempeño (Tabla 3). Las diferencias frente a los demás modelos no son significativas con la prueba de McNemar, ya que el tamaño de la prueba limita la potencia. La clase más difícil es Normal-like (F1 = 0,59), que se confunde con Luminal A.

Tabla 3

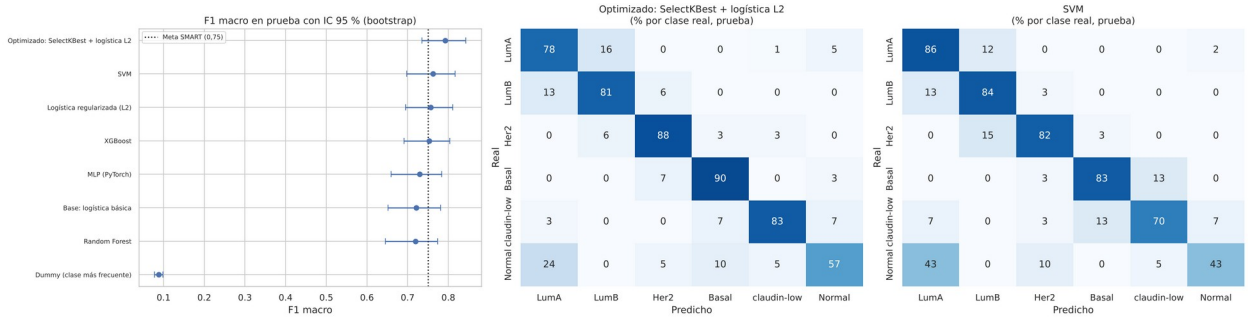
Clasificación del subtipo PAM50 en el conjunto de prueba

Modelo	Exactitud	F1 macro	IC 95 % F1	AUC-ROC
Final: SelectKBest + logística L2	0,804	0,792	[0,735; 0,843]	0,967
SVM	0,800	0,762	[0,698; 0,817]	0,968
Logística regularizada (L2)	0,786	0,757	[0,695; 0,811]	0,969
XGBoost	0,789	0,753	[0,691; 0,804]	0,969
MLP (PyTorch)	0,768	0,729	[0,659; 0,784]	0,962
Base: logística básica	0,765	0,721	[0,652; 0,781]	0,958
Random Forest	0,775	0,719	[0,645; 0,774]	0,960

Modelo	Exactitud	F1 macro	IC 95 % F1	AUC-ROC
Dummy (clase más frecuente)	0,358	0,088	[0,078; 0,098]	0,500

Figura 2

F1 macro en prueba con intervalos de confianza y matrices de confusión

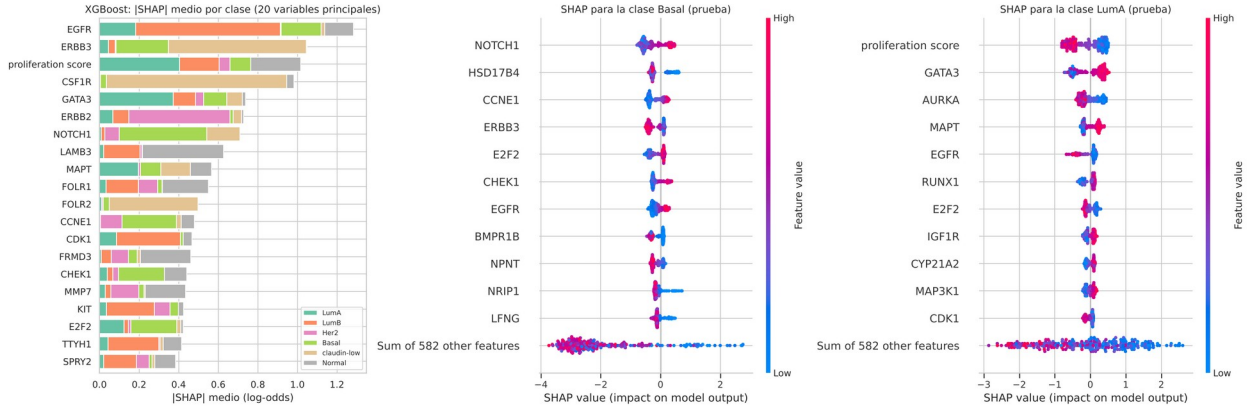


Interpretabilidad

En la regresión, los genes de proliferación (AURKA, CCNB1, CDK1) elevan el NPI estimado, mientras que BCL2, RUNX1 y STAT5B, asociados a tumores luminales de buen pronóstico, lo reducen. En la clasificación, los valores SHAP muestran que los modelos usan los marcadores conocidos de cada subtipo (Figura 3): ERBB2 para HER2, GATA3 y ERBB3 para los luminales, la proliferación para separar Luminal A de Luminal B, y EGFR y NOTCH1 para Basal (Parker et al., 2009; Prat et al., 2010).

Figura 3

Valores SHAP de XGBoost por clase y para los subtipos Basal y Luminal A



Segmentación de Pacientes

K-Means con K = 4 fue el algoritmo elegido: el codo y un máximo local de la silueta coinciden en ese valor, y los clústeres son muy estables (ARI medio de 0,93 en submuestras). La estructura se mantiene en validación y prueba (Tabla 4). Los clústeres difieren en NPI, supervivencia y mortalidad por cáncer ($p < 0,001$; Tabla 5). El clúster 2 concentra pacientes de una sola cohorte y sus genes distintivos no forman una firma biológica coherente, por lo que se interpreta como un probable efecto de lote.

Tabla 4

Estabilidad de la segmentación con K-Means (K = 4) por subconjunto

Subconjunto	n	Silueta	ARI PAM50	% C0	% C1	% C2	% C3
Entrenamiento	1.332	0,158	0,209	19,3	32,3	8,2	40,2
Validación	285	0,155	0,199	14,0	35,4	7,4	43,2
Prueba	286	0,150	0,215	20,6	29,4	6,6	43,4

Tabla 5

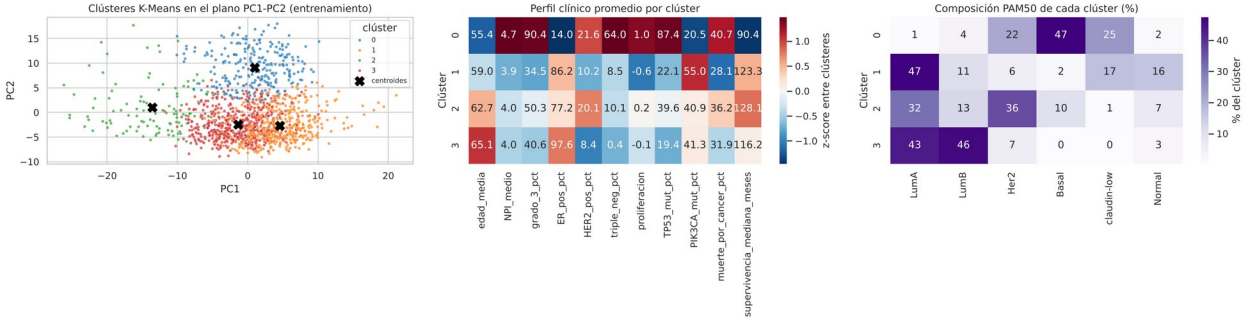
Perfiles de los clústeres en la cohorte completa

Clúster	% pacientes	Perfil	% mortalidad por cáncer
0	18,7	ER negativo (86 %), alta proliferación, TP53 mutado; Basal, claudin-low y HER2	41
1	32,3	Luminal de baja proliferación; Luminal A, Normal-like y claudin-low	28
2	7,8	Mezcla de HER2 y Luminal A; 82,6 % de la cohorte C3 (probable efecto de lote)	36
3	41,1	Luminal con proliferación intermedia; Luminal B y Luminal A	32

Nota. Mortalidad = proporción de pacientes fallecidas por la enfermedad durante el seguimiento.

Figura 4

Clústeres en el plano de componentes principales, perfil clínico y composición por subtipo



Cumplimiento de los Objetivos

Todos los objetivos SMART se cumplieron en el conjunto de prueba (Tabla 6).

Tabla 6

Cumplimiento de los objetivos SMART

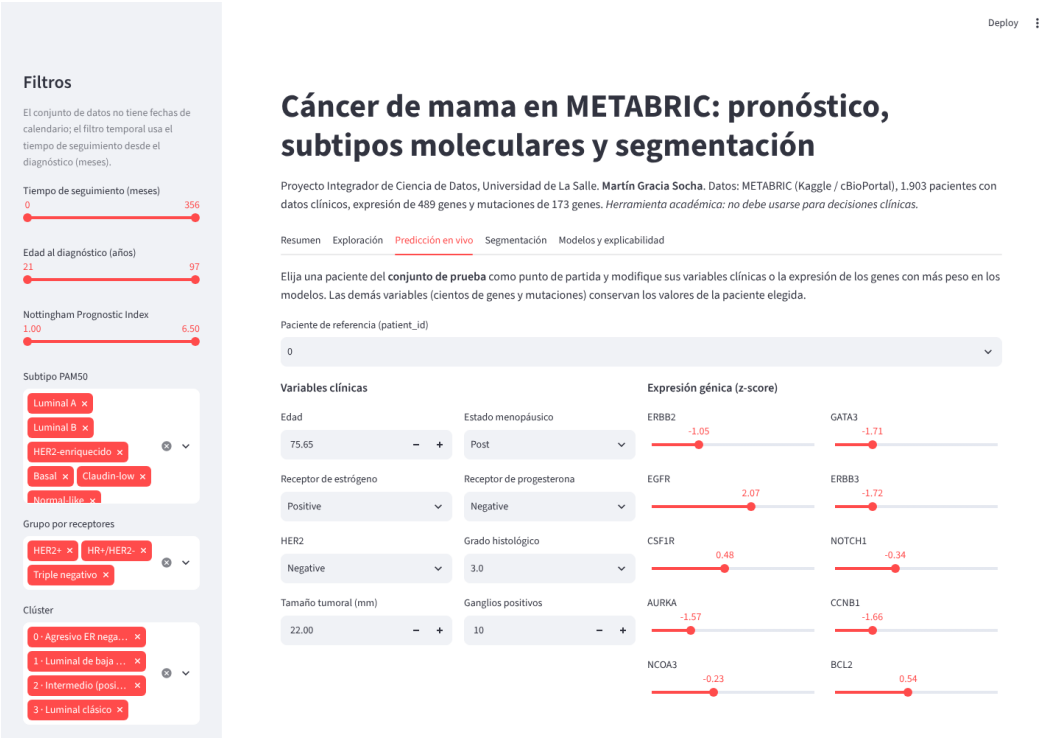
Objetivo	Criterio	Resultado	Cumple
1. Regresión	$R^2 \geq 0{,}20$ en prueba	$R^2 = 0{,}260$	Sí
1. Regresión	RMSE menor que el modelo base (prueba)	0,902 vs. 0,949	Sí
2. Clasificación	F1 macro ≥ 0,75 en prueba	F1 = 0,792	Sí
2. Clasificación	Superar al modelo base en CV (0,698)	F1 CV = 0,739	Sí
2. Clasificación	Brecha train − CV < 0,15	brecha = 0,123	Sí
3. Clustering	K-Means (codo y silueta) + segundo algoritmo + perfiles	K = 4; silueta prueba = 0,150; Ward y DBSCAN evaluados	Sí

Comunicación de Resultados

Los resultados se presentan en un dashboard construido con Streamlit (Streamlit Inc., s. f.), con filtros dinámicos, indicadores clave, curvas de supervivencia de Kaplan y Meier (1958), predicción en vivo para un perfil editable y la visualización de los clústeres en el espacio de componentes principales (Figura 5).

Figura 5

Pestaña de predicción en vivo del dashboard



Discusión

El primer hallazgo es que la biología del tumor explica una parte modesta pero real del pronóstico clínico: alrededor de una cuarta parte de la varianza del NPI sin usar sus componentes. Es un resultado esperable, porque el tamaño tumoral y la afectación ganglionar dependen también del momento del diagnóstico y no solo de la agresividad del tumor. Que modelos tan distintos como Ridge y XGBoost converjan en el mismo desempeño sugiere que la señal disponible es esencialmente lineal y está dominada por la proliferación.

El segundo hallazgo es que la expresión génica identifica el subtipo con un desempeño alto (F1 macro = 0,79; AUC = 0,97), muy por encima de los receptores clínicos. Esto respalda el valor de los perfiles moleculares en la práctica. El resultado es coherente con la definición de PAM50, que se basa en la expresión, pero el proyecto lo alcanza con un panel de genes distinto y sin usar directamente los 50 genes del ensayo. La dificultad con Normal-like es conocida en la

literatura: este subtipo se asocia con una baja proporción de células tumorales en la muestra más que con una biología propia (Prat et al., 2010).

El tercer hallazgo es metodológico. La segmentación no supervisada recupera la división biológica principal, ER positivo frente a ER negativo, y perfiles con mortalidad distinta, pero también capta diferencias técnicas entre centros. Este efecto de lote solo se detectó al cruzar los clústeres con la cohorte, lo que muestra la importancia de validar los resultados no supervisados con variables externas. En cuanto al sobreajuste, la selección de variables dentro del *pipeline* y la regularización fuerte fueron más eficaces que los ensambles o la red neuronal, lo cual es habitual cuando el número de variables (cerca de 600) se acerca al de pacientes.

Limitaciones

- El conjunto de prueba (286 pacientes) limita la potencia para detectar diferencias pequeñas entre modelos.
- Los datos provienen de un único estudio con cohortes del Reino Unido y Canadá; no se validó en una población externa.
- Se usó un subconjunto de 489 genes preseleccionado en la versión de Kaggle, no el transcriptoma completo.
- El NPI es un índice clínico aproximado; un análisis de supervivencia directo podría aprovechar mejor el seguimiento.

Conclusiones

El proyecto cumplió los tres objetivos planteados. Un modelo lineal regularizado estima el NPI con $R^2 = 0{,}26$ a partir de la biología del tumor; un clasificador sencillo e interpretable predice el subtipo PAM50 con F1 macro = 0,79 y bajo sobreajuste; y la segmentación identifica perfiles de riesgo con significado biológico, además de un efecto de lote que conviene corregir. El diseño sin fuga de información, la selección de modelos con reglas fijadas de antemano y el uso único del conjunto de prueba hacen que estas cifras sean estimaciones honestas del desempeño en pacientes nuevas.

Trabajo Futuro

- Corregir el efecto de lote entre cohortes con ComBat (Johnson et al., 2007) antes de segmentar.
- Modelar la supervivencia directamente con modelos de Cox regularizados o bosques de supervivencia.
- Validar los modelos en una cohorte externa, como TCGA-BRCA.
- Calibrar las probabilidades del clasificador antes de cualquier uso en apoyo a la decisión.

Referencias

Alharbi, R. (2020). *Breast cancer gene expression profiles (METABRIC)* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/raghadalharbi/breast-cancer-gene-expression-profiles-metabric

Bergsma, W. (2013). A bias-correction for Cramér's V and Tschuprow's T. *Journal of the Korean Statistical Society, 42*(3), 323–328. https://doi.org/10.1016/j.jkss.2012.10.002

Cerami, E., Gao, J., Dogrusoz, U., Gross, B. E., Sumer, S. O., Aksoy, B. A., Jacobsen, A., Byrne, C. J., Heuer, M. L., Larsson, E., Antipin, Y., Reva, B., Goldberg, A. P., Sander, C. y Schultz, N. (2012). The cBio cancer genomics portal: An open platform for exploring multidimensional cancer genomics data. *Cancer Discovery, 2*(5), 401–404. https://doi.org/10.1158/2159-8290.CD-12-0095

Chawla, N. V., Bowyer, K. W., Hall, L. O. y Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research, 16*, 321–357. https://doi.org/10.1613/jair.953

Chen, T. y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). Association for Computing Machinery. https://doi.org/10.1145/2939672.2939785

Curtis, C., Shah, S. P., Chin, S.-F., Turashvili, G., Rueda, O. M., Dunning, M. J., Speed, D., Lynch, A. G., Samarajiwa, S., Yuan, Y., Gräf, S., Ha, G., Haffari, G., Bashashati, A., Russell, R., McKinney, S., METABRIC Group, Langerød, A., Green, A., … Aparicio, S. (2012). The genomic and transcriptomic architecture of 2,000 breast tumours reveals novel subgroups. *Nature, 486*(7403), 346–352. https://doi.org/10.1038/nature10983

Efron, B. y Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall/CRC. https://doi.org/10.1201/9780429246593

Ester, M., Kriegel, H.-P., Sander, J. y Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. En *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining* (pp. 226–231). AAAI Press.

Goldhirsch, A., Wood, W. C., Coates, A. S., Gelber, R. D., Thürlimann, B., Senn, H.-J. y Panel members. (2011). Strategies for subtypes—Dealing with the diversity of breast cancer: Highlights of the St Gallen International Expert Consensus on the Primary Therapy of Early Breast Cancer 2011. *Annals of Oncology*, *22*(8), 1736–1747. https://doi.org/10.1093/annonc/mdr304

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., … Oliphant, T. E. (2020). Array programming with NumPy. *Nature*, *585*(7825), 357–362. https://doi.org/10.1038/s41586-020-2649-2

Hastie, T., Tibshirani, R. y Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2.ª ed.). Springer. https://doi.org/10.1007/978-0-387-84858-7

Haybittle, J. L., Blamey, R. W., Elston, C. W., Johnson, J., Doyle, P. J., Campbell, F. C., Nicholson, R. I. y Griffiths, K. (1982). A prognostic index in primary breast cancer. *British Journal of Cancer*, *45*(3), 361–366. https://doi.org/10.1038/bjc.1982.62

Hubert, L. y Arabie, P. (1985). Comparing partitions. *Journal of Classification*, *2*(1), 193–218. https://doi.org/10.1007/BF01908075

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, *9*(3), 90–95. https://doi.org/10.1109/MCSE.2007.55

Johnson, W. E., Li, C. y Rabinovic, A. (2007). Adjusting batch effects in microarray expression data using empirical Bayes methods. *Biostatistics*, *8*(1), 118–127. https://doi.org/10.1093/biostatistics/kxj037

Kaplan, E. L. y Meier, P. (1958). Nonparametric estimation from incomplete observations. *Journal of the American Statistical Association, 53*(282), 457–481. https://doi.org/10.1080/01621459.1958.10501452

Lemaître, G., Nogueira, F. y Aridas, C. K. (2017). Imbalanced-learn: A Python toolbox to tackle the curse of imbalanced datasets in machine learning. *Journal of Machine Learning Research, 18*(17), 1–5. https://jmlr.org/papers/v18/16-365.html

Little, R. J. A. y Rubin, D. B. (2019). *Statistical analysis with missing data* (3.ª ed.). Wiley. https://doi.org/10.1002/9781119482260

Lundberg, S. M. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. En I. Guyon, U. von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan y R. Garnett (Eds.), *Advances in Neural Information Processing Systems 30* (pp. 4765–4774). Curran Associates.

Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N. y Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence, 2*(1), 56–67. https://doi.org/10.1038/s42256-019-0138-9

McKinney, W. (2010). Data structures for statistical computing in Python. En S. van der Walt y J. Millman (Eds.), *Proceedings of the 9th Python in Science Conference* (pp. 56–61). https://doi.org/10.25080/Majora-92bf1922-00a

McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika, 12*(2), 153–157. https://doi.org/10.1007/BF02295996

Paik, S., Shak, S., Tang, G., Kim, C., Baker, J., Cronin, M., Baehner, F. L., Walker, M. G., Watson, D., Park, T., Hiller, W., Fisher, E. R., Wickerham, D. L., Bryant, J. y Wolmark, N. (2004). A multigene assay to predict recurrence of tamoxifen-treated, node-negative breast cancer. *The New England Journal of Medicine, 351*(27), 2817–2826. https://doi.org/10.1056/NEJMoa041588

Parker, J. S., Mullins, M., Cheang, M. C. U., Leung, S., Voduc, D., Vickery, T., Davies, S., Fauron, C., He, X., Hu, Z., Quackenbush, J. F., Stijleman, I. J., Palazzo, J., Marron, J. S., Nobel, A. B., Mardis, E., Nielsen, T. O., Ellis, M. J., Perou, C. M. y Bernard, P. S. (2009). Supervised risk predictor of breast cancer based on intrinsic subtypes. *Journal of Clinical Oncology*, *27*(8), 1160–1167. https://doi.org/10.1200/JCO.2008.18.8370

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Köpf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., … Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. En *Advances in Neural Information Processing Systems 32* (pp. 8024–8035). Curran Associates.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M. y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830. https://jmlr.org/papers/v12/pedregosa11a.html

Pereira, B., Chin, S.-F., Rueda, O. M., Vollan, H.-K. M., Provenzano, E., Bardwell, H. A., Pugh, M., Jones, L., Russell, R., Sammut, S.-J., Tsui, D. W. Y., Liu, B., Dawson, S.-J., Abraham, J., Northen, H., Peden, J. F., Mukherjee, A., Turashvili, G., Green, A. R., … Caldas, C. (2016). The somatic mutation profiles of 2,433 breast cancers refine their genomic and transcriptomic landscapes. *Nature Communications*, *7*, Artículo 11479. https://doi.org/10.1038/ncomms11479

Prat, A., Parker, J. S., Karginova, O., Fan, C., Livasy, C., Herschkowitz, J. I., He, X. y Perou, C. M. (2010). Phenotypic and molecular characterization of the claudin-low intrinsic subtype of breast cancer. *Breast Cancer Research, 12*(5), Artículo R68. https://doi.org/10.1186/bcr2635

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

Satopää, V., Albrecht, J., Irwin, D. y Raghavan, B. (2011). Finding a "kneedle" in a haystack: Detecting knee points in system behavior. En *2011 31st International Conference on Distributed Computing Systems Workshops* (pp. 166–171). IEEE. https://doi.org/10.1109/ICDCSW.2011.20

Sotiriou, C., Wirapati, P., Loi, S., Harris, A., Fox, S., Smeds, J., Nordgren, H., Farmer, P., Praz, V., Haibe-Kains, B., Desmedt, C., Larsimont, D., Cardoso, F., Peterse, H., Nuyten, D., Buyse, M., Van de Vijver, M. J., Bergh, J., Piccart, M. y Delorenzi, M. (2006). Gene expression profiling in breast cancer: Understanding the molecular basis of histologic grade to improve prognosis. *Journal of the National Cancer Institute, 98*(4), 262–272. https://doi.org/10.1093/jnci/djj052

Streamlit Inc. (s. f.). *Streamlit* (Versión 1.66.1) [Software]. https://streamlit.io

Sung, H., Ferlay, J., Siegel, R. L., Laversanne, M., Soerjomataram, I., Jemal, A. y Bray, F. (2021). Global cancer statistics 2020: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: A Cancer Journal for Clinicians, 71*(3), 209–249. https://doi.org/10.3322/caac.21660

van Buuren, S. y Groothuis-Oudshoorn, K. (2011). mice: Multivariate imputation by chained equations in R. *Journal of Statistical Software*, *45*(3), 1–67. https://doi.org/10.18637/jss.v045.i03

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., … SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods, 17*(3), 261–272. https://doi.org/10.1038/s41592-019-0686-2

Ward, J. H., Jr. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association, 58*(301), 236–244. https://doi.org/10.1080/01621459.1963.10500845

Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software, 6*(60), Artículo 3021. https://doi.org/10.21105/joss.03021