Guion de la Sustentación Final

Proyecto Integrador METABRIC: Actividad 9

Martín Gracia Socha

Facultad de Ingeniería, Universidad de La Salle

Ciencia de Datos (2026-2): Maestría en Inteligencia Artificial

Fabián Camilo Castro Riveros

28 de noviembre de 2026

Archivos ejecutables y recursos de esta entrega	
Presentación con guion	https://github.com/MartinGia/metabric-proyecto-integrador/blob/main/reports/entregas/Actividad9_Presentacion_Sustentacion.pptx
Presentación sin guion	https://github.com/MartinGia/metabric-proyecto-integrador/blob/main/reports/entregas/Actividad9_Presentacion_Sustentacion_sin_guion.pptx
Dashboard en línea	https://metabric-proyecto-integrador.streamlit.app
Repositorio	https://github.com/MartinGia/metabric-proyecto-integrador

Guion de la Sustentación Final

El guion acompaña las 15 diapositivas de la presentación. La duración estimada es de 16 minutos y 45 segundos, incluida una demostración en vivo del dashboard de dos minutos y medio. El mismo texto aparece en las notas del orador de la versión con guion. Antes de empezar, conviene abrir el dashboard en una pestaña del navegador para no depender de la carga durante la demostración.

Tabla 1

Distribución del tiempo por diapositiva

N.º	Diapositiva	Tiempo
1	Portada	0:30
2	Mensaje central	1:00
3	Problema y objetivos	1:15
4	Datos	1:15
5	Metodología sin fuga de información	1:30
6	Regresión del NPI	1:15
7	Clasificación del subtipo	1:15
8	Optimización del sobreajuste	1:00
9	Interpretabilidad	1:00
10	Segmentación	1:00
11	Efecto de lote	1:00
12	Dashboard (demostración en vivo)	2:30
13	Cumplimiento SMART	0:45
14	Limitaciones y próximos pasos	1:00
15	Cierre	0:30

Diapositiva 1: Portada (0:30)

Buenos días. Soy Martín Gracia Socha y presento el Proyecto Integrador de Ciencia de Datos. Trabajé con METABRIC, un estudio de cáncer de mama que combina datos clínicos y genómicos, para responder tres preguntas sobre pronóstico, subtipo molecular y perfiles de pacientes. En los próximos quince minutos les mostraré el problema, los datos, la metodología, los resultados y el dashboard, y cerraré con las limitaciones.

Diapositiva 2: Mensaje central (1:00)

Empiezo por las conclusiones. Primera: sin usar las variables con las que se calcula, la biología del tumor explica el 26 % de la variación del índice pronóstico de Nottingham. Segunda: la expresión génica identifica el subtipo molecular con un F1 macro de 0,79 y un AUC de 0,97 en pacientes que el modelo nunca vio. Tercera: los datos se agrupan en cuatro perfiles, aunque uno de ellos resultó ser un artefacto técnico. Todas estas cifras salen del conjunto de prueba, que se abrió una sola vez al final, y todas las metas SMART se cumplieron.

Diapositiva 3: Problema y objetivos (1:15)

El cáncer de mama es el cáncer más diagnosticado del mundo, con unos 2,3 millones de casos al año, y no es una sola enfermedad. Se clasifica en subtipos moleculares con pronósticos distintos, y en la clínica el pronóstico se resume con el NPI, que combina tamaño, ganglios y grado. Planteé tres preguntas, cada una con una meta medible. Primera, una regresión: ¿cuánto del NPI explica la biología, sin usar sus componentes? La meta era un R^2 de al menos 0,20. Segunda, una clasificación de seis subtipos con F1 macro de al menos 0,75 y bajo sobreajuste. Tercera, una segmentación no supervisada con al menos dos algoritmos.

Diapositiva 4: Datos (1:15)

METABRIC reúne 1.904 pacientes con 693 variables: 31 clínicas, la expresión de 489 genes y 173 indicadores de mutación. El análisis exploratorio mostró que Luminal A es el subtipo más común y que tres de cada cuatro tumores son positivos para receptores de estrógeno. Los genes de proliferación aumentan con el NPI, y en la proyección de componentes principales ya se ve que los subtipos se separan. Los faltantes no son aleatorios: el estadio falta en el 26,5 % de los casos y depende del centro de reclutamiento, así que lo excluí de los predictores.

Diapositiva 5: Metodología sin fuga de información (1:30)

La decisión metodológica más importante fue evitar la fuga de información. Primero apliqué solo reglas determinísticas, fila por fila; por ejemplo, deduje 18 grados faltantes de la propia fórmula del NPI. Después fijé una partición 70/15/15 estratificada por subtipo. Todo lo que aprende de los datos, como percentiles, imputación, escalado y codificación, quedó dentro de

un pipeline que se ajusta solo con entrenamiento. Los hiperparámetros se eligieron con validación cruzada de cinco pliegues, y las reglas para escoger el modelo final se fijaron antes de ver la prueba. Además, quité del problema de regresión el tamaño, los ganglios y el grado, porque el NPI se calcula con ellos.

Diapositiva 6: Regresión del NPI (1:15)

En regresión comparé Ridge, ElasticNet, Random Forest y XGBoost. En la gráfica de error en prueba se ve que los cuatro quedan prácticamente empatados y todos mejoran al modelo base basado en proliferación. Ridge alcanza un R^2 de 0,26, por encima de la meta de 0,20. Como las diferencias entre modelos no son significativas, apliqué la regla de un error estándar y elegí el más simple. La lectura es que la señal biológica disponible es esencialmente lineal y está dominada por la proliferación.

Diapositiva 7: Clasificación del subtipo (1:15)

En clasificación, el contraste más claro es este: con solo los tres receptores que se miden en la clínica, ER, PR y HER2, el F1 es de 0,38; con la expresión génica sube a 0,79. El clasificador final alcanza un AUC de 0,97 y una exactitud del 80 %. La clase más difícil es Normal-like, que se confunde con Luminal A, algo que también reporta la literatura. La prueba de McNemar no distingue entre los mejores modelos, porque con 286 pacientes tiene poca potencia; por eso la elección se basó en la validación cruzada.

Diapositiva 8: Optimización del sobreajuste (1:00)

Los primeros clasificadores memorizaban: la brecha entre entrenamiento y validación cruzada estaba entre 0,22 y 0,27. Para corregirlo, seleccioné los 200 genes más informativos dentro de cada pliegue y usé una regresión logística muy regularizada. La brecha bajó a 0,123, por debajo de la meta de 0,15, sin perder desempeño. Quiero subrayar que la configuración con el F1 más alto se descartó porque no cumplía la regla de sobreajuste fijada de antemano.

Diapositiva 9: Interpretabilidad (1:00)

Para confiar en un modelo hay que entender qué usa. Con valores SHAP, los modelos redescubren la biología conocida: ERBB2 identifica el subtipo HER2; GATA3 y ERBB3, los

luminales; la proliferación separa Luminal A de Luminal B; EGFR y NOTCH1 señalan los tumores basales, y los genes inmunes caracterizan claudin-low. En la regresión, los genes de proliferación suben el NPI estimado y BCL2 lo baja. Esto da validez biológica a las predicciones.

Diapositiva 10: Segmentación (1:00)

Para la segmentación reduje los genes a diez componentes principales y apliqué K-Means. El método del codo y la silueta coinciden en cuatro grupos, que son muy estables entre submuestras. Comparé con el clustering jerárquico de Ward, y descarté DBSCAN porque dejaba a buena parte de las pacientes como ruido. El clúster 0 reúne tumores receptor negativos, muy proliferativos y con TP53 mutado, y tiene la mayor mortalidad por cáncer, 41 %, frente a 28 % del grupo luminal de baja proliferación.

Diapositiva 11: Efecto de lote (1:00)

Ahora, un hallazgo que no esperaba. El 82,6 % del clúster 2 viene de una sola cohorte, la C3, que solo representa el 38,5 % de la muestra, y sus genes no forman una firma biológica coherente. Lo más probable es que ese grupo refleje diferencias técnicas entre centros, lo que se llama efecto de lote. La lección metodológica es que los resultados no supervisados siempre deben contrastarse con variables externas. Aun así, la segmentación en conjunto se explica mucho más por la biología que por la cohorte.

Diapositiva 12: Dashboard (demostración en vivo) (2:30)

Todo esto se comunica en un dashboard publicado en Streamlit. Voy a hacer una demostración breve. Primero, el resumen con los indicadores y las curvas de supervivencia. Si filtro por el subtipo Basal, cambian los indicadores. En la pestaña de predicción elijo una paciente de prueba, subo la expresión de ERBB2 y cambio HER2 a positivo, y la probabilidad del subtipo HER2 aumenta. En segmentación la ubico entre los clústeres, en 2D o 3D. [Si no hay conexión, mostrar la captura de esta diapositiva].

Diapositiva 13: Cumplimiento SMART (0:45)

Resumo el cumplimiento de las metas. En regresión, R^2 de 0,26 frente a una meta de 0,20 y mejor error que el modelo base. En clasificación, F1 de 0,79 frente a 0,75, mejor que el modelo base en validación cruzada y con una brecha de sobreajuste de 0,12. En segmentación, cuatro perfiles justificados con el codo y la silueta, un segundo algoritmo y perfiles interpretables. Las seis metas se cumplieron.

Diapositiva 14: Limitaciones y próximos pasos (1:00)

El trabajo tiene limitaciones. La prueba es pequeña, los datos vienen de un solo estudio sin validación externa, se usaron 489 genes preseleccionados y el NPI es solo una aproximación al pronóstico. Como próximos pasos propongo corregir el efecto de lote con ComBat, modelar la supervivencia directamente, validar en una cohorte externa como TCGA y calibrar las probabilidades antes de cualquier uso clínico.

Diapositiva 15: Cierre (0:30)

Para cerrar: la biología del tumor anticipa parte del pronóstico, identifica el subtipo con alta precisión y agrupa a las pacientes en perfiles de riesgo, con un diseño reproducible y sin fuga de información. El código, los cuadernos y el dashboard están en el repositorio público. Muchas gracias; quedo atento a sus preguntas.